

Генеративные модели

Лекция 2: Модели со скрытыми
переменными

Постановка задачи

Пусть у нас есть набор данных $\{\mathbf{x}_i\}_{i=1}^n$,

$\mathbf{x}_i \in \mathbb{R}^m$ — вектор, представляющий объект

$p_{data}(\mathbf{x})$ описывает как объекты распределены в пространстве $\mathbb{R}^m$

Цель: найти неизвестное распределение $p_{data}(\mathbf{x})$

Зная $p_{data}(\mathbf{x})$ мы сможем оценивать вероятность новых объектов и генерировать новые

Проблема высокой размерности

Объекты находятся в пространстве высокой размерности

Прямая оценка $p_{data}(\mathbf{x})$ в таких пространствах затруднена

Найти истинное распределение $p_{data}(\mathbf{x})$ почти невозможно

Будем искать аппроксимацию внутри некоторого заранее заданного *параметрического семейства распределений* $p_{\theta}(\mathbf{x})$

θ — параметры модели

Ищем θ^* , которые максимизируют правдоподобие:

$$\theta^* = \arg \max_{\theta} \sum_{i=1}^n \log p_{\theta}(\mathbf{x}_i)$$

Связь правдоподобия и KL -дивергенции

Наша задача — найти такие параметры θ , при которых $p_{\theta}(\mathbf{x})$ будет максимально близко к $p_{data}(\mathbf{x})$:

$$p_{\theta}(\mathbf{x}) \approx p_{data}(\mathbf{x})$$

Будем искать такие параметры θ , которые минимизируют дивергенцию между истинным и модельным распределениями:


$$\min_{\theta} D(p_{data}(\mathbf{x}) \parallel p_{\theta}(\mathbf{x}))$$

Минимизация прямой KL — дивергенции эквивалента максимизации правдоподобия

Обучение авторегрессионных моделей

Объекты в реальном мире – многомерные случайные величины

Прямое моделирование $p_{\theta}(\mathbf{x}) = p_{\theta}(x_1, x_2, \dots, x_D)$ – сложная задача из-за проклятия размерности



Разложение многомерной плотности

Разложим совместную вероятность на произведение условных:


$$p_{\theta}(\mathbf{x}) = p_{\theta}(x_1, x_2, \dots, x_D) = p_{\theta}(x_1) \cdot p_{\theta}(x_2|x_1) \cdot p_{\theta}(x_3|x_1, x_2) \cdot \dots \cdot p_{\theta}(x_D|x_1, x_2, \dots, x_{D-1})$$

$$= \prod_j^D p_{\theta}(x_i|\mathbf{x}_{1:j-1})$$

$\mathbf{x}_{1:j-1}$ — вектор всех компонент объекта $\mathbf{x}$ до позиции j

Теперь задача максимизации правдоподобия принимает вид:

$$\theta^* = \underset{\theta}{argmax} \sum_{i=1}^n \sum_j^D \log p_{\theta}(x_{ij}|\mathbf{x}_{i,1:j-1})$$





Обучение авторегрессионных моделей

В начале обучения модель часто совершает ошибки, которые с каждым шагом накапливаются

Решение:

Принудительно подавать на вход модели правильные данные (*teacher forcing*)



При генерации модель использует собственные предсказания

План

- Модели со скрытыми переменными

- ЕМ алгоритм

- Вариационный вывод

Модели со скрытыми переменными


Проблема высокой размерности

Ищем θ , которые максимизируют правдоподобие:

$$\theta^* = \arg \max_{\theta} \sum_{i=1}^n \log p_{\theta}(\mathbf{x}_i)$$

Объекты в реальном мире – многомерные случайные величины

Прямое моделирование $p_{\theta}(\mathbf{x}) = p_{\theta}(x_1, x_2, \dots, x_D)$ – сложная задача из-за проклятия размерности



Модели со скрытыми переменными

Предположим, что помимо наблюдаемой переменной $\mathbf{x}$ в нашей задаче есть некоторая скрытая переменная $\mathbf{z}$, которая влияет на $\mathbf{x}$

Мы не можем измерить ее напрямую, но знаем, что она есть

Мы можем записать совместную плотность и разложить ее на условную и априорную:

$$p_{\theta}(\mathbf{x}, \mathbf{z}) = p_{\theta}(\mathbf{x}|\mathbf{z}) \cdot p_{\theta}(\mathbf{z})$$

$p_{\theta}(\mathbf{z})$ — априорное распределение на скрытых переменных

$p_{\theta}(\mathbf{x}|\mathbf{z})$ — условное распределение наблюдаемых данных

Проинтегрируем по всем $\mathbf{z}$, чтобы найти правдоподобие:

$$p_{\theta}(\mathbf{x}) = \int p_{\theta}(\mathbf{x}, \mathbf{z}) d\mathbf{z} = \int p_{\theta}(\mathbf{x}|\mathbf{z}) \cdot p_{\theta}(\mathbf{z}) d\mathbf{z}$$

Модели со скрытыми переменными

Наша цель – по-прежнему максимизация правдоподобия:

$$\theta^* = \arg \max_{\theta} \sum_{i=1}^n \log p_{\theta}(\mathbf{x}_i) \quad \rightarrow \quad \theta^* = \arg \max_{\theta} \sum_{i=1}^n \log \int p_{\theta}(\mathbf{x}_i | \mathbf{z}_i) \cdot p_{\theta}(\mathbf{z}_i) d\mathbf{z}_i$$

Мы заменили одно сложное распределение $p_{\theta}(\mathbf{x})$ на интеграл от двух более простых:

$$\log p_{\theta}(\mathbf{x}) = \log \int p_{\theta}(\mathbf{x} | \mathbf{z}) \cdot p_{\theta}(\mathbf{z}) d\mathbf{z} \quad \rightarrow \quad \max_{\theta}$$


Выбирая подходящие распределения для $p_{\theta}(\mathbf{x} | \mathbf{z})$ и $p_{\theta}(\mathbf{z})$, мы можем либо получить аналитическое решение для θ^* , либо использовать методы оптимизации

Gaussian Mixture Models

- Реальные данные редко описываются одним простым распределением
- Мы можем представить сложное распределение как взвешенную сумму (смесь) более простых распределений

Самый популярный представитель – *модели гауссовских смесей (Gaussian Mixture Models)*

- Сначала случайно берём одну из K компонент
- Затем семплируем вектор $\mathbf{x}$ из выбранного распределения $\mathcal{N}(\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$
- Номер компоненты, из которой пришел вектор, является скрытой переменной $\mathbf{z}$ (мы её не наблюдаем)



Gaussian Mixture Models

Скрытая переменная $\mathbf{z}$ — это бинарный вектор $\mathbf{z} = \{0,1\}^K$, где z_k означает принадлежность к k -ой компоненте

Априорная вероятность $p_{\theta}(\mathbf{z})$ задается весами смеси π_k , при этом:

$$\sum_{k=1}^K \pi_k = 1$$

Если точка пришла из k -ой компоненты, то ее вероятность описывается гауссианой:

$$p_{\theta}(\mathbf{x}|\mathbf{z}_k = 1) = \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$


Итоговое правдоподобие:

$$p_{\theta}(\mathbf{x}) = \sum_{k=1}^K p(\mathbf{z}_k = 1|\boldsymbol{\theta}) \cdot p(\mathbf{x}|\mathbf{z}_k = 1, \boldsymbol{\theta}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

MLE для моделей со скрытыми переменными

Нужно вычислить сложный интеграл:

$$\sum_{i=1}^n \log p_{\theta}(\mathbf{x}_i) = \sum_{i=1}^n \log \int p_{\theta}(\mathbf{x}_i | \mathbf{z}_i) \cdot p_{\theta}(\mathbf{z}_i) d\mathbf{z}_i$$




Попробуем оценить этот интеграл методом Монте-Карло:

$$p_{\theta}(\mathbf{x}) = \int p_{\theta}(\mathbf{x} | \mathbf{z}) \cdot p(\mathbf{z}) d\mathbf{z} = \mathbb{E}_{p(\mathbf{z})}[p_{\theta}(\mathbf{x} | \mathbf{z})] \approx \frac{1}{K} \sum_{k=1}^K p_{\theta}(\mathbf{x} | \mathbf{z}_k)$$

MLE для моделей со скрытыми переменными

- Большинство сэмплов $\mathbf{z}_k$ попадут в «бесполезные» области и декодер сгенерирует шум



Наше априорное распределение $p(\mathbf{z})$ ничего не знает об изображениях $\mathbf{x}$

В многомерном пространстве объем «пустого» пространства огромен по сравнению с объемом полезной области

Чтобы получить надежную оценку интеграла, нам понадобится экспоненциально большое число сэмплов K

ЕМ алгоритм

Модели со скрытыми переменными

В моделях со скрытыми переменными наша цель – максимизировать логарифм правдоподобия $\log p_{\theta}(X)$

Из-за наличия скрытых переменных правдоподобие выражается через интеграл (сумму):

$$p_{\theta}(X) = \int p_{\theta}(X, Z) dZ$$

Итоговая функция, которую мы максимизируем, содержит интеграл внутри логарифма:

$$\log p_{\theta}(X) = \log \int p_{\theta}(X, Z) dZ \rightarrow \max_{\theta}$$

Наивная оценка не работает:

Попытка оценить эти интегралы методом Монте-Карло проваливается из-за проклятия размерности

Формула Байеса

Введем понятия:

X — наши реальные, неполные данные

$\{X, Z\}$ — полные данные

Мы не знаем точные значения Z , но можем вычислить апостериорное распределение:

$$p_{\theta}(Z|X) = \frac{p_{\theta}(X|Z) \cdot p_{\theta}(Z)}{p_{\theta}(X)}$$

- $p_{\theta}(Z|X)$ — **апостериорное распределение**, вероятность того, что скрытые переменные приняли значение Z , после того как мы увидели данные X
- $p_{\theta}(X|Z)$ — **правдоподобие**, вероятность увидеть данные X , если скрытые переменные равны Z
- $p_{\theta}(Z)$ — **априорное распределение**, насколько вероятны значения Z до наблюдений
- $p_{\theta}(X)$ — **обоснованность (evidence)** вероятность увидеть данные X

ЕМ алгоритм

- Пусть у нас есть уже есть некоторая оценка параметров θ_{old}
- Будем итеративно выполнять 2 шага

E-шаг (Expectation):

Используя текущие значения θ_{old} , находим апостериорное распределение $p_{\theta_{old}}(\mathbf{Z}|\mathbf{X})$ и вычисляем матожидание логарифма правдоподобия для полных данных $\{\mathbf{X}, \mathbf{Z}\}$:

$$Q(\theta, \theta_{old}) = \int p_{\theta_{old}}(\mathbf{Z}|\mathbf{X}) \cdot \log p_{\theta}(\mathbf{X}, \mathbf{Z}) d\mathbf{Z}$$

M-шаг (Maximization):

Обновляем оценку параметров θ , новые значения выбираются таким образом, чтобы максимизировать $Q(\theta, \theta_{old})$:

$$\theta_{new} = \arg \max_{\theta} Q(\theta, \theta_{old})$$

ЕМ алгоритм

Каждая итерация *ЕМ* алгоритма гарантировано не уменьшает истинное правдоподобие:

$$\log p_{\theta_{new}}(\mathbf{X}) \geq \log p_{\theta_{old}}(\mathbf{X})$$

Чтобы вычислить знаменатель $p_{\theta}(\mathbf{X})$ в формуле для апостериорного распределения, нам нужно взять интеграл:

$$p_{\theta}(\mathbf{X}) = \int p_{\theta}(\mathbf{X}, \mathbf{Z}) d\mathbf{Z}$$

В случае **GMM** мы можем получить аналитическое решение:

$$p_{\theta}(\mathbf{X}) = \sum_{k=1}^K p(\mathbf{Z} = k | \boldsymbol{\theta}) \cdot p(\mathbf{X} | \mathbf{Z} = k, \boldsymbol{\theta})$$

ЕМ алгоритм

ЕМ алгоритм прекрасен, но для более сложных моделей вычислить истинное апостериорное распределение $p_{\theta_{old}}(\mathbf{Z}|\mathbf{X})$ на *E-stage* аналитически невозможно

- Будем аппроксимировать распределение $p_{\theta_{old}}(\mathbf{Z}|\mathbf{X})$
- В этом и состоит идея *вариационного вывода* (*Variational Inference*)

Вариационный вывод

Вариационный вывод

Наша цель — оценить $\log p_{\theta}(\mathbf{x})$:

$$\log p_{\theta}(\mathbf{x}) = \log \int p_{\theta}(\mathbf{x}, \mathbf{z}) d\mathbf{z}$$

Введем вспомогательное распределение $q(\mathbf{z})$ — произвольную плотность над скрытыми переменными $\mathbf{z}$

Идея:

Мы не знаем $\log p_{\theta}(\mathbf{x})$, но можем попытаться построить для него некую **нижнюю границу** (*lower bound*), которую будем оптимизировать

Вывод *ELBO* (1)

Умножим и разделим выражение для $\log p_{\theta}(\mathbf{x})$ на $q(\mathbf{z})$:

$$\log p_{\theta}(\mathbf{x}) = \log \int p_{\theta}(\mathbf{x}, \mathbf{z}) d\mathbf{z} = \log \int \frac{q(\mathbf{z})}{q(\mathbf{z})} p_{\theta}(\mathbf{x}, \mathbf{z}) d\mathbf{z} =$$

$$\log \mathbb{E}_q \left[\frac{p_{\theta}(\mathbf{x}, \mathbf{z})}{q(\mathbf{z})} \right] \geq \mathbb{E}_q \log \frac{p_{\theta}(\mathbf{x}, \mathbf{z})}{q(\mathbf{z})} = \mathcal{L}_{q,\theta}(\mathbf{x})$$

Неравенство Йенсена:

$$\log \mathbb{E}[X] \geq \mathbb{E}[\log X]$$


Мы получили **вариационную нижнюю оценку** (*Evidence Lower Bound, ELBO*), которая утверждает, что для любого $q(\mathbf{z})$:

$$\log p_{\theta}(\mathbf{x}) \geq \mathcal{L}_{q,\theta}(\mathbf{x})$$

Вывод *ELBO* (1)

$q(\mathbf{z})$ будем называть *вариационным распределением*

Насколько далеко наша нижняя граница $\mathcal{L}_{q,\theta}(\mathbf{x})$ находится от истинного значения $\log p_{\theta}(\mathbf{x})$?



Вывод *ELBO* (2)

Перепишем выражение для ***ELBO***:

$$\mathcal{L}_{q,\theta}(\mathbf{x}) = \int q(\mathbf{z}) \log \frac{p_{\theta}(\mathbf{x}, \mathbf{z})}{q(\mathbf{z})} d\mathbf{z} = \int q(\mathbf{z}) \log \frac{p_{\theta}(\mathbf{z}|\mathbf{x}) \cdot p_{\theta}(\mathbf{x})}{q(\mathbf{z})} d\mathbf{z} =$$


$$\int q(\mathbf{z}) \log p_{\theta}(\mathbf{x}) d\mathbf{z} + \int q(\mathbf{z}) \log \frac{p_{\theta}(\mathbf{z}|\mathbf{x})}{q(\mathbf{z})} d\mathbf{z} = \log p_{\theta}(\mathbf{x}) \int q(\mathbf{z}) d\mathbf{z} + \int q(\mathbf{z}) \log \frac{p_{\theta}(\mathbf{z}|\mathbf{x})}{q(\mathbf{z})} d\mathbf{z} =$$

$$\log p_{\theta}(\mathbf{x}) + \int q(\mathbf{z}) \log \frac{p_{\theta}(\mathbf{z}|\mathbf{x})}{q(\mathbf{z})} d\mathbf{z} = \log p_{\theta}(\mathbf{x}) + KL(q(\mathbf{z})||p_{\theta}(\mathbf{z}|\mathbf{x}))$$

Вывод *ELBO* (2)

Зазор между $\log p_{\theta}(\mathbf{x})$ и $\mathcal{L}_{q,\theta}(\mathbf{x})$ равен KL -дивергенции между вариационным распределением $q(\mathbf{z})$ и истинным апостериорным распределением $p_{\theta}(\mathbf{z}|\mathbf{x})$:

$$\log p_{\theta}(\mathbf{x}) - \mathcal{L}_{q,\theta}(\mathbf{x}) = KL(q(\mathbf{z})||p_{\theta}(\mathbf{z}|\mathbf{x}))$$



Вывод *ELBO* (2)

Получим ещё одно выражение для ***ELBO***, используя разложение $p_{\theta}(\mathbf{x}, \mathbf{z}) = p_{\theta}(\mathbf{x}|\mathbf{z}) \cdot p(\mathbf{z})$

$$\mathcal{L}_{q,\theta}(\mathbf{x}) = \int q(\mathbf{z}) \log \frac{p_{\theta}(\mathbf{x}, \mathbf{z})}{q(\mathbf{z})} d\mathbf{z} = \int q(\mathbf{z}) \log p_{\theta}(\mathbf{x}|\mathbf{z}) d\mathbf{z} + \int q(\mathbf{z}) \log \frac{p(\mathbf{z})}{q(\mathbf{z})} d\mathbf{z}$$

$$\underbrace{\mathbb{E}_q[\log p_{\theta}(\mathbf{x}|\mathbf{z})]}_{\text{Reconstruction loss}} - \underbrace{KL(q(\mathbf{z})||p(\mathbf{z}))}_{\text{Regularization loss}}$$

Итоговое правдоподобие:

$$\log p_{\theta}(\mathbf{x}) = \mathcal{L}_{q,\theta}(\mathbf{x}) + KL(q(\mathbf{z})||p_{\theta}(\mathbf{z}|\mathbf{x})) =$$

$$\mathbb{E}_q[\log p_{\theta}(\mathbf{x}|\mathbf{z})] - KL(q(\mathbf{z})||p(\mathbf{z})) + KL(q(\mathbf{z})||p_{\theta}(\mathbf{z}|\mathbf{x}))$$

Выводы

Вместо прямой максимизации правдоподобия $\log p_{\theta}(\mathbf{x})$ будем максимизировать его нижнюю границу $\mathcal{L}_{q,\theta}(\mathbf{x})$ по параметрам вариационного распределения q и параметрам модели θ :

$$\max_{q,\theta} \mathcal{L}_{q,\theta}(\mathbf{x})$$

Максимизируя $\mathcal{L}_{q,\theta}(\mathbf{x})$, мы одновременно стараемся сделать 2 вещи:

1. Увеличить правдоподобие наблюдаемых данных
2. Уменьшить зазор $KL(q(\mathbf{z})||p_{\theta}(\mathbf{z}|\mathbf{x}))$, аппроксимировав $p_{\theta}(\mathbf{z}|\mathbf{x})$ с помощью $q(\mathbf{z})$

ЕМ алгоритм

Мы получили следующее выражение:


$$\log p_{\theta}(\mathbf{x}) = \mathcal{L}_{q,\theta}(\mathbf{x}) + KL(q(\mathbf{z})||p_{\theta}(\mathbf{z}|\mathbf{x}))$$

- ЕМ алгоритм можно интерпретировать как метод координатного подъёма (*coordinate ascent*) по **ELBO**
- Он итеративно оптимизирует $\mathcal{L}_{q,\theta}(\mathbf{x})$, поочерёдно фиксируя либо параметры вариационного распределения $q(\mathbf{z})$, либо параметры модели θ


Е – шаг

Е-шаг:

- Фиксируем θ_{old} и ищем оптимальное $q(\mathbf{z})$, которое максимизирует $\mathcal{L}_{q,\theta_{old}}(\mathbf{x})$




- $\log p_{\theta}(\mathbf{x})$ не зависит от $q(\mathbf{z})$, поэтому $\mathcal{L}_{q,\theta_{old}}(\mathbf{x})$ максимальна, когда $KL(q(\mathbf{z})||p_{\theta}(\mathbf{z}|\mathbf{x})) = 0$
- Наилучший выбор для $q(\mathbf{z})$ – это апостериорное распределение $\log p_{\theta}(\mathbf{x})$




M – шаг

M -шаг:

- Фиксируем найденное распределение $q(\mathbf{z})$ и пытаемся увеличить $\mathcal{L}_{q, \theta_{old}}(\mathbf{x})$




- Увеличение нижней границы гарантирует $\mathcal{L}_{q, \theta}(\mathbf{x})$ увеличение $\log p_{\theta}(\mathbf{x})$ (если мы не в максимуме)
- Распределение $q(\mathbf{z})$ было определено на основе старых параметров θ_{old} , поэтому оно не равно апостериорному распределению $p_{\theta_{new}}(\mathbf{z}|\mathbf{x})$



ЕМ – алгоритм

- Работу ЕМ-алгоритма можно рассмотреть в пространстве параметров
- На Е-шаге мы строим нижнюю границу $\mathcal{L}_{q,\theta_{old}}(\mathbf{x})$, которая касается $\log p_{\theta}(\mathbf{x})$ в точке θ_{old}
- На М-шаге ищем максимум этой нижней границы (точка θ_{new}), что приводит к большему значению $\log p_{\theta_{new}}(\mathbf{x})$



Спасибо за внимание!