Генеративные модели

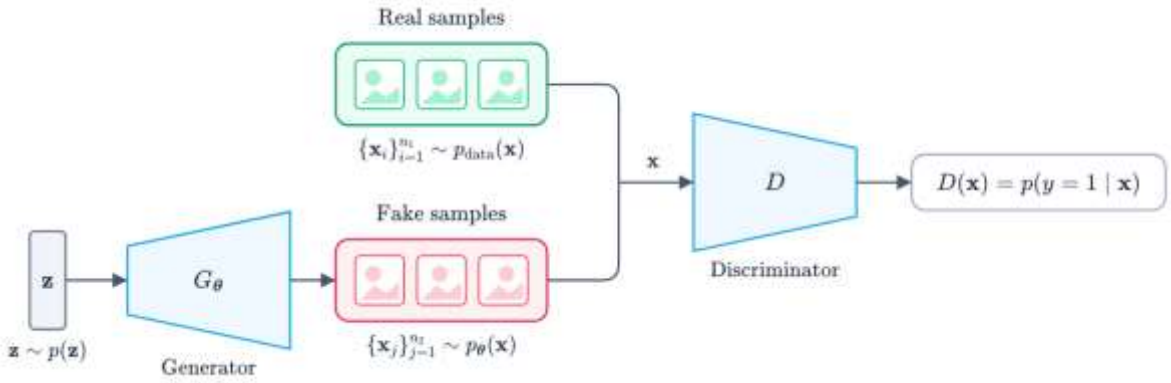
Лекция 6: *Score Matching*

Generative Adversarial Networks

Обучение GAN реализуется через состязание двух нейросетей:

- ***Генератор*** $\boldsymbol{G_\theta}$:
  создаёт реалистичные данные $\mathbf{x} = \boldsymbol{G_\theta}(\boldsymbol{z})$ из $\boldsymbol{z} \sim p(\boldsymbol{z})$

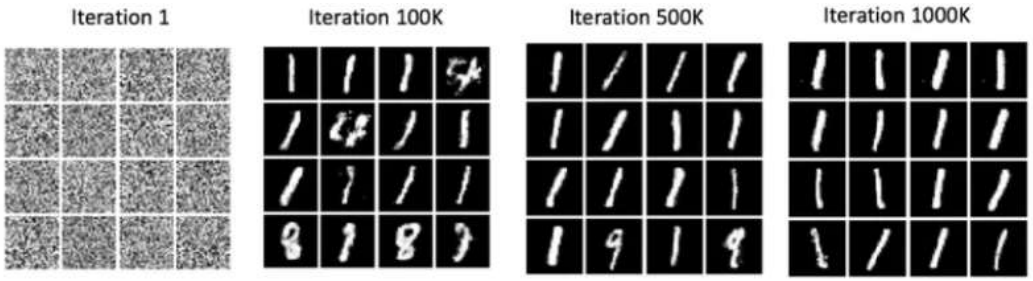
- ***Дискриминатор*** $\boldsymbol{D}$:
  бинарный классификатор, который получает на вход объект $\mathbf{x}$ и выдает вероятность $D(\mathbf{x})$, что $\mathbf{x}$ – реальный



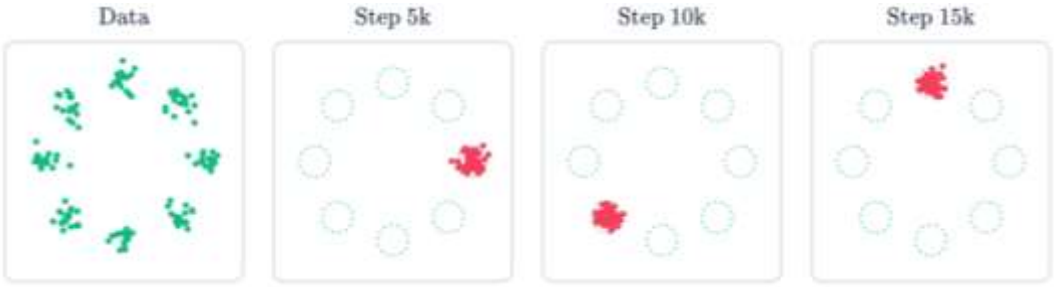
Mode Collapse

Коллапс мод (***mode collapse***) – главная практическая проблема *GAN*

Генератор «схлопывается» и начинает генерировать только одну или несколько мод распределения



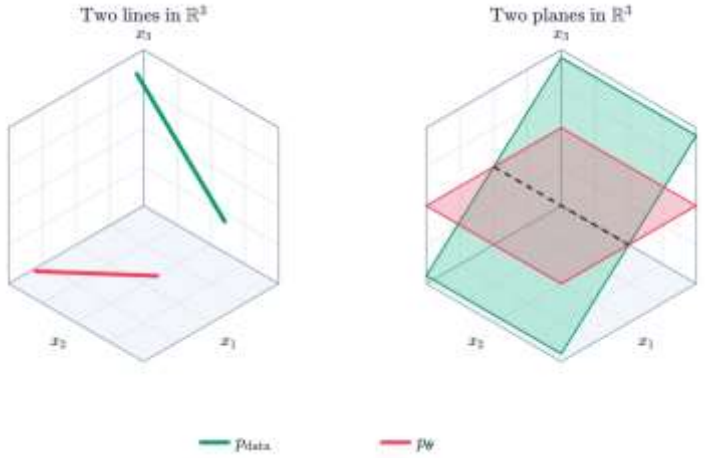
- *D* оценивает объекты отдельно, однообразие не наказывается
- Генератору выгодно рисовать то, что *D* сейчас считает реальным и перескакивать с моды на моду



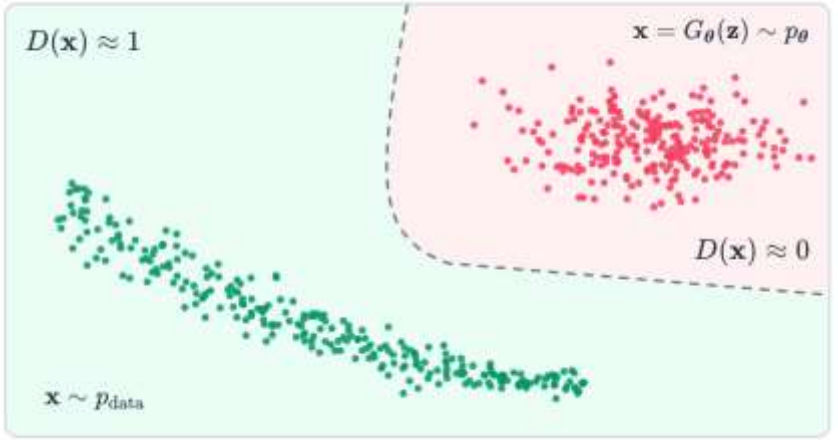
Более глубокая причина – дивергенция, которую минимизирует *GAN*

Непересекающиеся носители

- Носитель – множество точек, где плотность > 0
- На низкоразмерных многообразиях p_{data} и p_{θ} почти гарантированно не пересекаются (***disjoint supports***)



- Дискриминатору очень легко провести разделяющую поверхность и стать идеальным классификатором
- $D(\mathbf{x}) \approx 1$ на реальных, $D(\mathbf{x}) \approx 0$ на сгенерированных данных



JSD при непересекающихся носителях

Jensen – Shannon:

$$JSD(p_{data} \,||\, p_{\boldsymbol{\theta}}) = \frac{1}{2} KL\left(p_{data}(\mathbf{x}) \,||\, \frac{p_{data}(\mathbf{x}) + p_{\boldsymbol{\theta}}(\mathbf{x})}{2}\right) + \frac{1}{2} KL\left(p_{\boldsymbol{\theta}}(\mathbf{x}) || \, \frac{p_{data}(\mathbf{x}) + p_{\boldsymbol{\theta}}(\mathbf{x})}{2}\right) =$$

$$\frac{1}{2}\int p_{data}(\mathbf{x}) \log \frac{p_{data}(\mathbf{x})}{m(\mathbf{x})} d\mathbf{x} + \frac{1}{2}\int p_{\boldsymbol{\theta}}(\mathbf{x}) \log \frac{p_{\boldsymbol{\theta}}(\mathbf{x})}{m(\mathbf{x})} d\mathbf{x} = \frac{1}{2}\int p_{data}(\mathbf{x}) \log \frac{p_{data}(\mathbf{x})}{p_{data}(\mathbf{x})/2} d\mathbf{x} +$$

$$+ \frac{1}{2}\int p_{\boldsymbol{\theta}}(\mathbf{x}) \log \frac{p_{\boldsymbol{\theta}}(\mathbf{x})}{p_{\boldsymbol{\theta}}(\mathbf{x})/2} d\mathbf{x} = \frac{1}{2}\log 2 + \frac{1}{2}\log 2 = \log 2$$

- Как только дискриминатор становится идеальным, JSD становится константой
- Обучение останавливается, поскольку градиенты становятся равными нулю

Wasserstein GAN

Мы не можем найти идеальную f, поэтому будем аппроксимировать ее с помощью нейросети критика $f_{\boldsymbol{\phi}}$ (***Critic***)

Обеспечение Липшицевости:

- Будем принудительно обрезать (***clipping***) все веса в диапазон $[-c, c]$ после каждого шага градиентного спуска
- Это гарантирует, что функция будет K −Липшицевой

Множество наших нейросетей $f_{\boldsymbol{\phi}}$ − это подмножество всех K −Липшицевых функций f:

$$K \cdot W(p_{data}, p_{\boldsymbol{\theta}}) = \max_{||f||_L \leq K} \left[\mathbb{E}_{p_{data}} f(\mathbf{x}) - \mathbb{E}_{p_{\boldsymbol{\theta}}} f(\mathbf{x})\right] \geq \max_{\boldsymbol{\phi} \in \boldsymbol{\Phi}} \left[\mathbb{E}_{p_{data}} f_{\boldsymbol{\phi}}(\mathbf{x}) - \mathbb{E}_{p_{\boldsymbol{\theta}}} f_{\boldsymbol{\phi}}(\mathbf{x})\right]$$

Wasserstein GAN

Функция потерь ***GAN***:

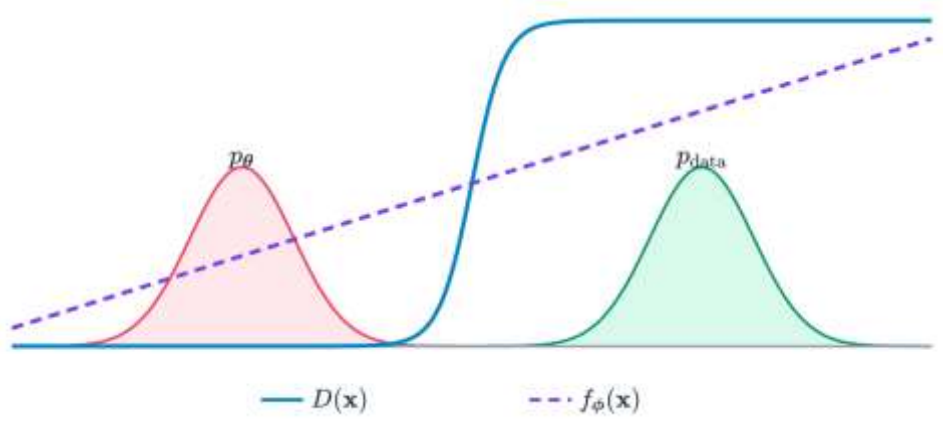
$$\min_{\boldsymbol{\theta}} \max_{\boldsymbol{\phi}} \left(\mathbb{E}_{p_{data}(\mathbf{x})} \log D_{\boldsymbol{\phi}}(\mathbf{x}) + \mathbb{E}_{p(\boldsymbol{z})} \log \left(1 - D_{\boldsymbol{\phi}}(G_{\boldsymbol{\theta}}(\boldsymbol{z})) \right) \right)$$

Функция потерь ***WGAN***:

$$\min_{\boldsymbol{\theta}} W(p_{data}, p_{\boldsymbol{\theta}}) \approx \min_{\boldsymbol{\theta}} \max_{\boldsymbol{\phi} \in \boldsymbol{\Phi}} \left[\mathbb{E}_{p_{data}(\mathbf{x})} f_{\boldsymbol{\phi}}(\mathbf{x}) - \mathbb{E}_{p(\boldsymbol{z})} f_{\boldsymbol{\phi}}(G_{\boldsymbol{\theta}}(\boldsymbol{z})) \right]$$

Основные отличия:

- Дискриминатор $D_{\boldsymbol{\phi}}$ → Критик $f_{\boldsymbol{\phi}}$ выдает любое число (оценку)
- Параметры критика $\boldsymbol{\phi}$ ограничены



$WGAN - GP$

Weight Clipping – очень плохой способ заставить критика быть K –Липшицевым и результат зависит от выбранного c

Идея ***$WGAN - GP$***:

Вместо того, чтобы обрезать веса $\boldsymbol{\phi}$, будем наказывать критика, если он нарушает 1 –Липшицево ограничение

1 –Липшицевость означает, что норма градиента критика $||\nabla f_{\boldsymbol{\phi}}(\mathbf{x})|| \leq 1$ ***в любой точке***

- Мы не можем проверять градиент везде
- Авторы показали, что достаточно проверить его на случайных точках между реальными x_{data} и поддельными x_{fake} данными

$WGAN - GP$

Gradient Penalty:

- Создаем случайный объект с помощью интерполяции:

$$\hat{\mathbf{x}} = \epsilon \cdot \mathbf{x}_{data} + (1 - \epsilon) \cdot \mathbf{x}_{fake}, \qquad \epsilon \sim U[0,1]$$

- Вычисляем градиент критика $f_{\boldsymbol{\phi}}$ в этой точке $\hat{\mathbf{x}}$ и штрафуем его если $||\nabla f_{\boldsymbol{\phi}}(\hat{\mathbf{x}})||_2$ отличается от 1

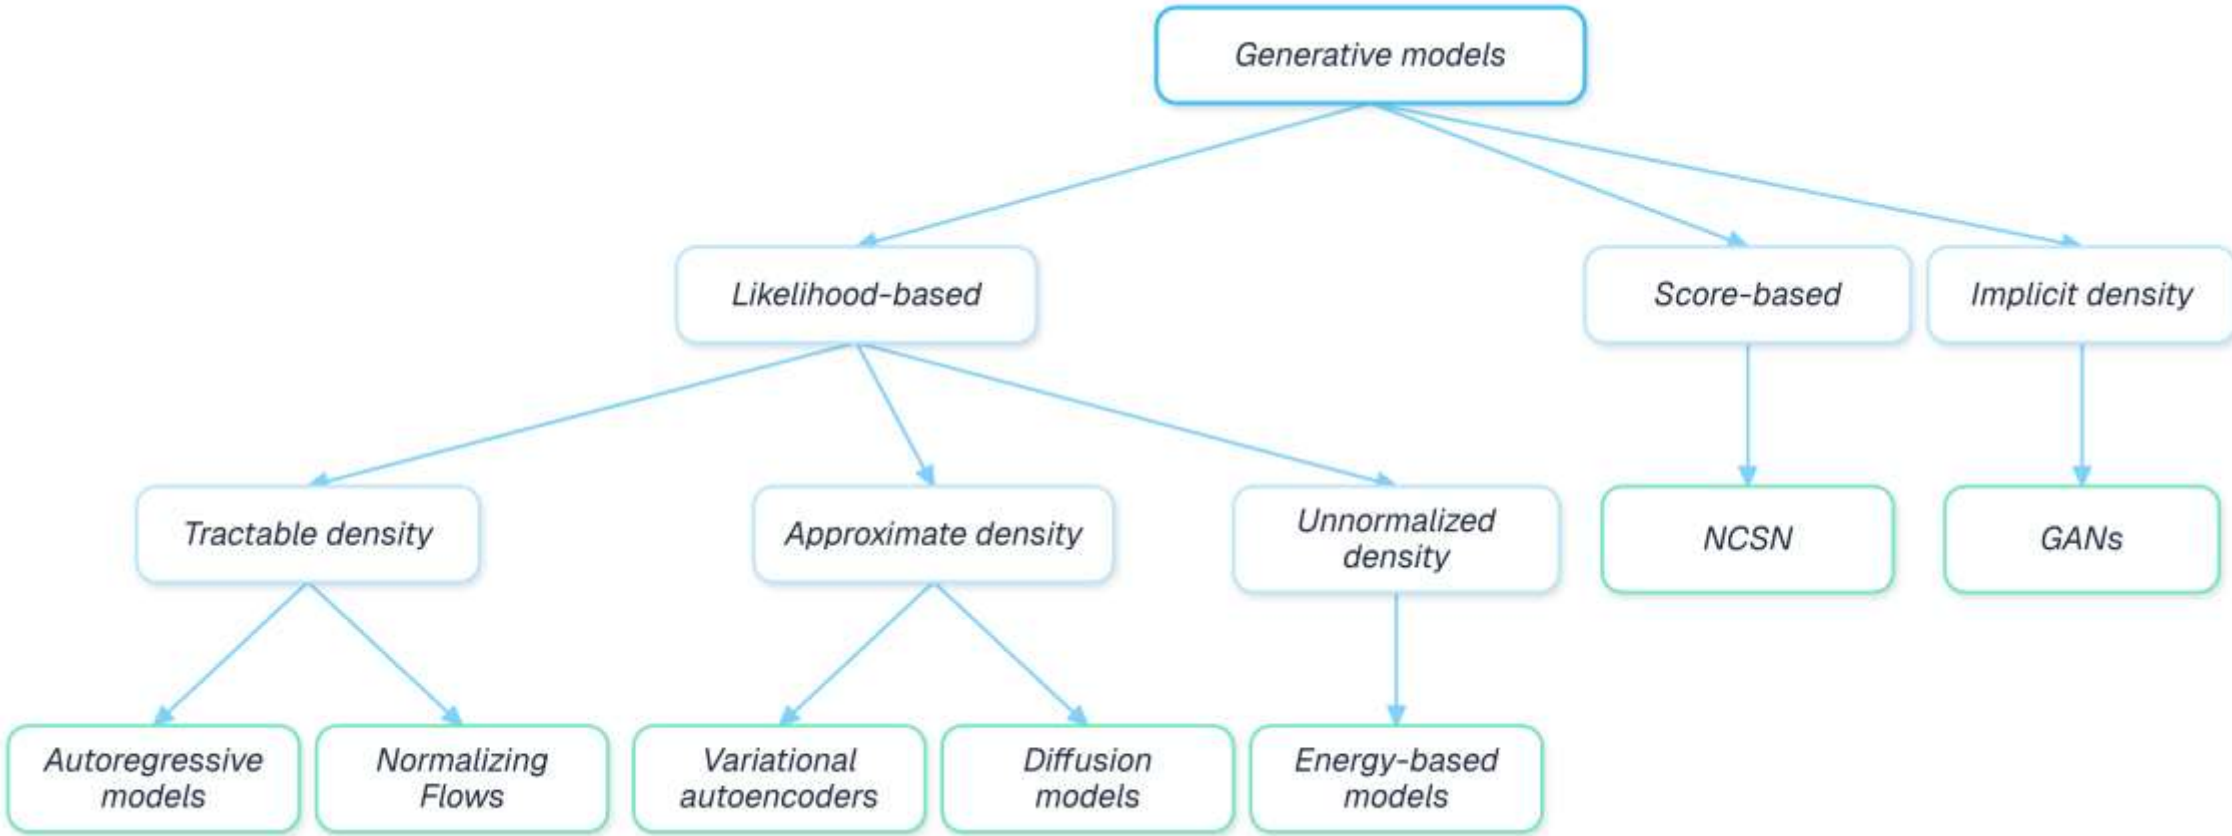
Функция потерь $\boldsymbol{WGAN - GP}$:

$$\mathcal{L} = \underbrace{\left[\mathbb{E}_{p(\mathbf{z})} f_{\boldsymbol{\phi}}(G_{\boldsymbol{\theta}}(\mathbf{z})) - \mathbb{E}_{p_{data}(\mathbf{x})} f_{\boldsymbol{\phi}}(\mathbf{x})\right]}_{WGAN\ Loss} + \underbrace{\lambda \cdot \mathbb{E}_{\hat{\mathbf{x}}}\left[\left(||\nabla f_{\boldsymbol{\phi}}(\hat{\mathbf{x}})||_2 - 1\right)^2\right]}_{Gradient\ Penalty}$$

План

- *Energy Based Models*
- *Score Matching*
- *Denoising Score Matching*
- *Noise Conditioned Score Network*

$Energy - Based\ Models$


Generative models
Likelihood-based
Score-based
Implicit density
Tractable density
Approximate density
Unnormalized density
NCSN
GANs
Autoregressive models
Normalizing Flows
Variational autoencoders
Diffusion models
Energy-based models

Проблемы генеративных моделей

AR-модели и нормализующие потоки точно считают правдоподобие, но платят за это ограничениями:

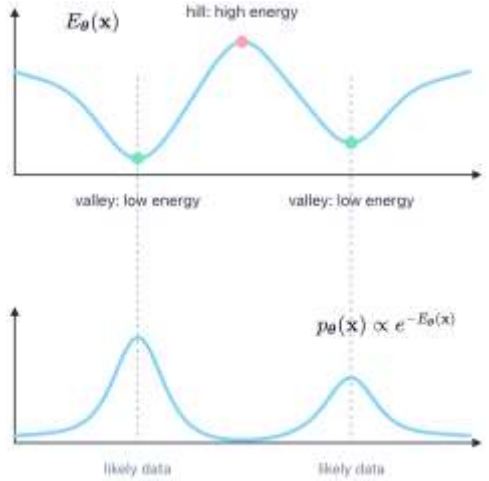
- *AR*-модели требуют заданного порядка при генерации
- Нормализующие потоки требуют обратимые преобразования в скрытое пространство
- *VAE* более гибкие, но оптимизируют *ELBO*

- Введем функцию энергии $E_{\boldsymbol{\theta}}(\mathbf{x})$
- Она будет принимать на вход объект $\mathbf{x}$ и выдавать одно число — энергию
- Ограничений на архитектуру нет (но дифференцируема)

Energy – Based Models

Функция $E_{\boldsymbol{\theta}}(\mathbf{x})$ определяет ландшафт в пространстве данных:

- Низкая энергия (впадины) – наиболее вероятные данные
- Высокая энергия (холмы) – маловероятные данные



EBM решает проблемы других моделей:

- $E_{\boldsymbol{\theta}}(\mathbf{x})$ не обязана быть обратимой
- $E_{\boldsymbol{\theta}}(\mathbf{x})$ не требует заданного порядка

- Будем учить нейросеть $E_{\boldsymbol{\theta}}(\mathbf{x})$ так, чтобы впадины были там, где находятся реальные данные

$Energy - Based\ Models$

Определим плотность $p_{\boldsymbol{\theta}}(\mathbf{x})$ через энергию с помощью распределения Больцмана:

$$p_{\boldsymbol{\theta}}(\mathbf{x}) = \frac{e^{-E_{\boldsymbol{\theta}}(\mathbf{x})}}{Z_{\boldsymbol{\theta}}}$$

- $e^{-E_{\boldsymbol{\theta}}(\mathbf{x})}$ – ненормализованная плотность
- $Z_{\boldsymbol{\theta}}$ – нормировочная константа (статистическая сумма)

$Z_{\boldsymbol{\theta}}$ – это интеграл по всему пространству данных:

$$Z_{\boldsymbol{\theta}} = \int e^{-E_{\boldsymbol{\theta}}(\mathbf{x})}\, d\mathbf{x}$$

- Для сложных высокоразмерных данных мы не можем вычислить этот интеграл
- Не зная $Z_{\boldsymbol{\theta}}$, мы не сможем найти $p_{\boldsymbol{\theta}}(\mathbf{x})$ и его градиент для обучения

$Energy - Based\ Models$

Найдем градиент логарифма плотности EBM:

$$\log p_{\boldsymbol{\theta}}(\mathbf{x}) = \log \frac{e^{-E_{\boldsymbol{\theta}}(\mathbf{x})}}{Z_{\boldsymbol{\theta}}} = \log e^{-E_{\boldsymbol{\theta}}(\mathbf{x})} - \log Z_{\boldsymbol{\theta}} = -E_{\boldsymbol{\theta}}(\mathbf{x}) - \log Z_{\boldsymbol{\theta}}$$

$$\nabla_{\boldsymbol{\theta}} \log p_{\boldsymbol{\theta}}(\mathbf{x}) = -\nabla_{\boldsymbol{\theta}} E_{\boldsymbol{\theta}}(\mathbf{x}) - \nabla_{\boldsymbol{\theta}} \log Z_{\boldsymbol{\theta}}$$

Вспомним, что $Z_{\boldsymbol{\theta}} = \int e^{-E_{\boldsymbol{\theta}}(\mathbf{x})}\, d\mathbf{x}$:

$$\nabla_{\boldsymbol{\theta}} \log Z_{\boldsymbol{\theta}} = \frac{1}{Z_{\boldsymbol{\theta}}} \nabla_{\boldsymbol{\theta}} Z_{\boldsymbol{\theta}} = \frac{1}{Z_{\boldsymbol{\theta}}} \nabla_{\boldsymbol{\theta}} \int e^{-E_{\boldsymbol{\theta}}(\mathbf{x})}\, d\mathbf{x} = \frac{1}{Z_{\boldsymbol{\theta}}} \int \nabla_{\boldsymbol{\theta}} e^{-E_{\boldsymbol{\theta}}(\mathbf{x})}\, d\mathbf{x}$$

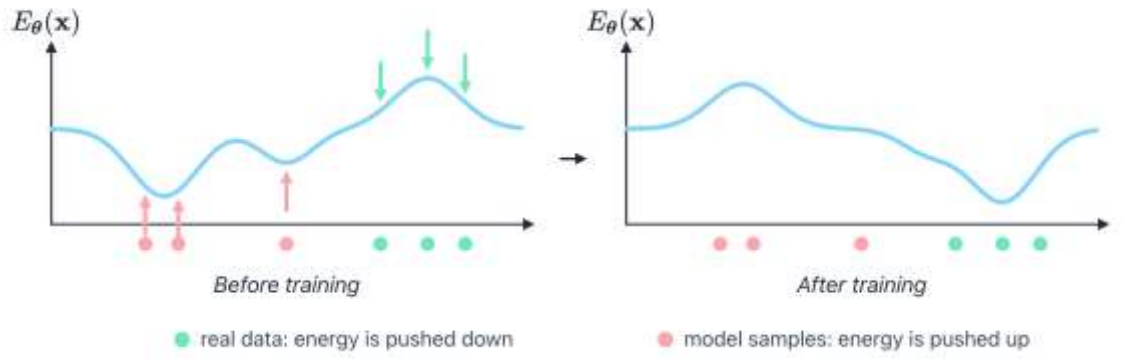
$$= \frac{1}{Z_{\boldsymbol{\theta}}} \int e^{-E_{\boldsymbol{\theta}}(\mathbf{x})} \cdot (-\nabla_{\boldsymbol{\theta}} E_{\boldsymbol{\theta}}(\mathbf{x}))\, d\mathbf{x} = \int \underbrace{\frac{e^{-E_{\boldsymbol{\theta}}(\mathbf{x})}}{Z_{\boldsymbol{\theta}}}}_{p_{\boldsymbol{\theta}}(\mathbf{x})} \cdot (-\nabla_{\boldsymbol{\theta}} E_{\boldsymbol{\theta}}(\mathbf{x}))\, d\mathbf{x} = -\mathbb{E}_{p_{\boldsymbol{\theta}}(\mathbf{x})} \nabla_{\boldsymbol{\theta}} E_{\boldsymbol{\theta}}(\mathbf{x})$$

Energy – Based Models

В итоге получаем:

$$\nabla_{\boldsymbol{\theta}} \mathbb{E}_{p_{data}(\mathbf{x})}[\log p_{\boldsymbol{\theta}}(\mathbf{x})] = -\mathbb{E}_{p_{data}(\mathbf{x})}[\nabla_{\boldsymbol{\theta}} E_{\boldsymbol{\theta}}(\mathbf{x})] + \mathbb{E}_{p_{\boldsymbol{\theta}}(\mathbf{x})}[\nabla_{\boldsymbol{\theta}} E_{\boldsymbol{\theta}}(\mathbf{x})]$$

- $-\mathbb{E}_{p_{data}(\mathbf{x})}[\nabla_{\boldsymbol{\theta}} E_{\boldsymbol{\theta}}(\mathbf{x})]$ – положительная фаза: реальные данные, энергия понижается
- $\mathbb{E}_{p_{\boldsymbol{\theta}}(\mathbf{x})}[\nabla_{\boldsymbol{\theta}} E_{\boldsymbol{\theta}}(\mathbf{x})]$ – отрицательная фаза: сэмплы модели, энергия повышается



$Energy - Based\ Models$

$$\nabla_{\boldsymbol{\theta}} \mathbb{E}_{p_{data}(\mathbf{x})}[\log p_{\boldsymbol{\theta}}(\mathbf{x})] = -\mathbb{E}_{p_{data}(\mathbf{x})}[\nabla_{\boldsymbol{\theta}} E_{\boldsymbol{\theta}}(\mathbf{x})] + \mathbb{E}_{p_{\boldsymbol{\theta}}(\mathbf{x})}[\nabla_{\boldsymbol{\theta}} E_{\boldsymbol{\theta}}(\mathbf{x})]$$

- Второе слагаемое требует сэмплов из модели, то есть оценки $\mathbb{E}_{p_{\boldsymbol{\theta}}(\mathbf{x})}[\dots]$
- Будем оценивать этот член с помощью метода Монте-Карло (***Markov Chain Monte Carlo***, ***MCMC***)

Введем понятие ***функции оценки*** (***score function***):

$$s_{\boldsymbol{\theta}}(\mathbf{x}) = \nabla_{\mathbf{x}} \log p_{\boldsymbol{\theta}}(\mathbf{x})$$

Найдем $score\ function$ для EBM:

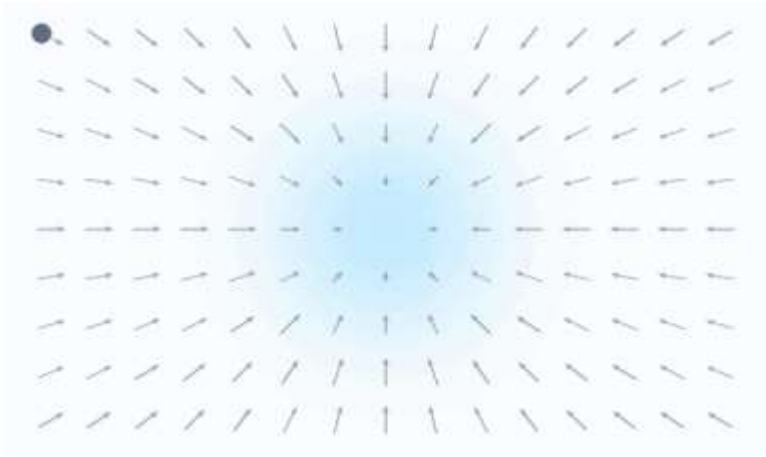
$$s_{\boldsymbol{\theta}}(\mathbf{x}) = \nabla_{\mathbf{x}} \log \frac{e^{-E_{\boldsymbol{\theta}}(\mathbf{x})}}{Z_{\boldsymbol{\theta}}} = \nabla_{\mathbf{x}} \log e^{-E_{\boldsymbol{\theta}}(\mathbf{x})} - \nabla_{\mathbf{x}} \log Z_{\boldsymbol{\theta}} = -\nabla_{\mathbf{x}} E_{\boldsymbol{\theta}}(\mathbf{x})$$

Langevin Dynamics

Для сэмплирования из $p_{\boldsymbol{\theta}}(\mathbf{x})$ будем использовать ***динамику Ланжевена*** (***Langevin Dynamics***):

$$\mathbf{x}_{t+1} = \mathbf{x}_t + \frac{\eta}{2}\nabla_{\mathbf{x}} \log p_{\boldsymbol{\theta}}(\mathbf{x}_t) + \sqrt{\eta}\boldsymbol{\epsilon}_t = \mathbf{x}_t + \frac{\eta}{2} s_{\boldsymbol{\theta}}(\mathbf{x}_t) + \sqrt{\eta}\boldsymbol{\epsilon}_t$$

- $\mathbf{x}_t -$ текущая точка
- $\eta -$ размер шага
- $\boldsymbol{\epsilon}_t \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I}) -$ шум

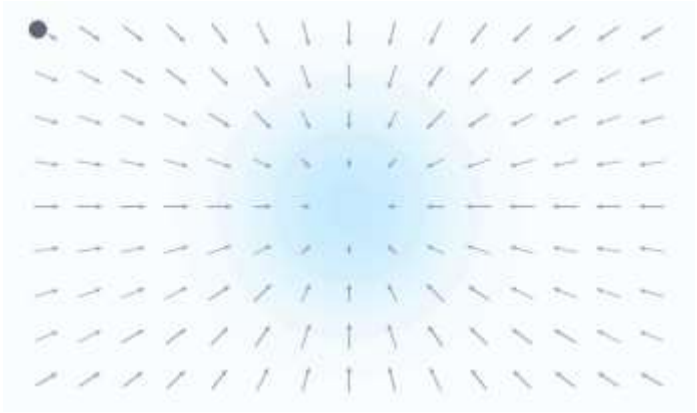


- Член $\frac{\eta}{2}\nabla_{\mathbf{x}} \log p_{\boldsymbol{\theta}}(\mathbf{x}_t)$ – это градиентный подъем, который толкает нашу точку $\mathbf{x}$ в направлении наибольшего возрастания плотности

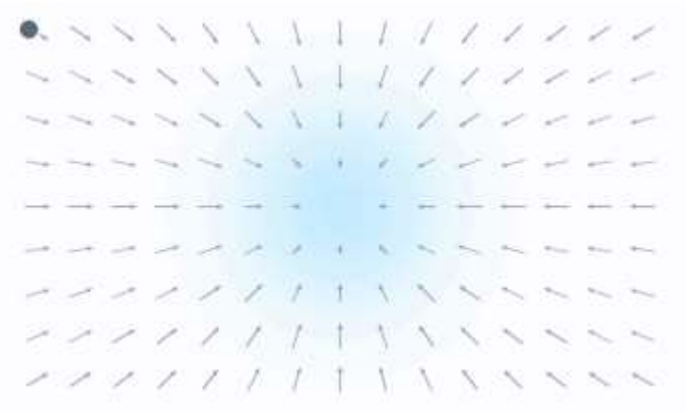
- Член $\sqrt{\eta}\boldsymbol{\epsilon}_t$ добавляет случайности и не дает нашей точке $\mathbf{x}$ застрять в локальном максимуме

Langevin Dynamics

- Малый η: распределение точное, сходимость медленная
- Большой η: сходимость быстрая, распределение неточное
- Можно использовать отжиг и сделать η_t



$\eta = 0.03$



$\eta = 0.2$

Теорема (***неформально***):

Пусть $\mathbf{x}_0$ – произвольный случайный вектор, тогда при мягких условиях регулярности сэмплы, полученные с помощью динамики

$$\mathbf{x}_{t+1} = \mathbf{x}_t + \frac{\eta}{2}\nabla_{\mathbf{x}} \log p_{\boldsymbol{\theta}}(\mathbf{x}_t) + \sqrt{\eta}\boldsymbol{\epsilon}_t, \qquad \boldsymbol{\epsilon}_t \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I})$$

будут распределены по $p_{\boldsymbol{\theta}}(\mathbf{x})$ при $\eta \to 0$ и $t \to \infty$

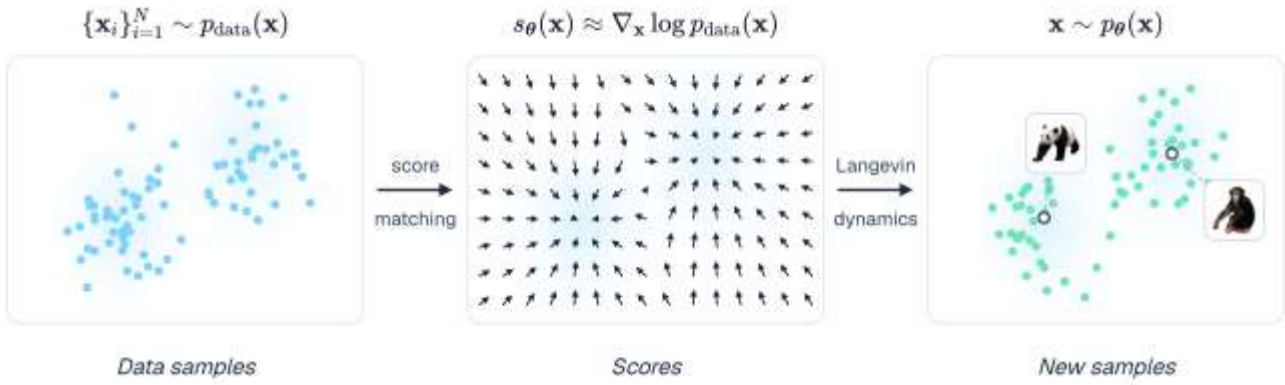
Score Matching

Проблемы *MCMC*

- Обучение с использованием *MCMC* обычно очень медленное, нестабильное и даёт смещённые градиенты

Идея:

- Попробуем обучать *score function* $s_{\theta}(\mathbf{x})$ напрямую
- Сэмплировать из выученного векторного поля будем с помощью динамики Ланжевена



Score Matching

Факт:

- Если *score*-функции двух распределений $q(\mathbf{x})$ и $p(\mathbf{x})$ равны, то и сами распределения равны ($q(\mathbf{x}) > 0$ и $p(\mathbf{x}) > 0$ для любого $\mathbf{x}$)

Дано: $\nabla_{\mathbf{x}} \log p(\mathbf{x}) = \nabla_{\mathbf{x}} \log q(\mathbf{x})$

Доказательство:

Проинтегрируем обе части выражения:

$$\log p(\mathbf{x}) = \log q(\mathbf{x}) + C$$

$$p(\mathbf{x}) = e^{C} \cdot e^{\log q(\mathbf{x})} = K \cdot q(\mathbf{x}) = q(\mathbf{x})$$

Score Matching

Цель ***score matching*** (***Hyvärinen*, 2005**) заключается в минимизации дивергенции Фишера:

$$D_F\left(p_{data}(\mathbf{x})||p_{\boldsymbol{\theta}}(\mathbf{x})\right) = \mathbb{E}_{p_{data}(\mathbf{x})}\left[\frac{1}{2}||\nabla_{\mathbf{x}}\log p_{\boldsymbol{\theta}}(\mathbf{x}) - \nabla_{\mathbf{x}}\log p_{data}(\mathbf{x})||^2\right]$$

$$= \frac{1}{2}\int p_{data}(\mathbf{x})\,||\nabla_{\mathbf{x}}\log p_{\boldsymbol{\theta}}(\mathbf{x}) - \nabla_{\mathbf{x}}\log p_{data}(\mathbf{x})||^2$$

- Минимизируя эту функцию потерь, мы заставляем *score*-функцию модели $s_{\boldsymbol{\theta}}(\mathbf{x})$ соответствовать *score*-функции реальных данных $s_{data}(\mathbf{x})$
- Если $s_{\boldsymbol{\theta}}(\mathbf{x}) \approx s_{data}(\mathbf{x})$, то $p_{\boldsymbol{\theta}}(\mathbf{x}) \approx p_{data}(\mathbf{x})$

Мы не знаем *score*-функцию реальных данных $s_{data}(\mathbf{x})$

Score Matching

Hyvärinen показал, что при определенных условиях регулярности функция потерь может быть переписана в виде:

$$D_F\left(p_{data}(\mathbf{x})||p_{\boldsymbol{\theta}}(\mathbf{x})\right) = \mathbb{E}_{p_{data}(\mathbf{x})}\left[\frac{1}{2}||s_{\boldsymbol{\theta}}(\mathbf{x}) - s_{data}(\mathbf{x})||^2\right] = \mathbb{E}_{p_{data}(\mathbf{x})}\left[\frac{1}{2}||s_{\boldsymbol{\theta}}(\mathbf{x})||^2 + tr\left(\nabla_{\mathbf{x}} s_{\boldsymbol{\theta}}(\mathbf{x})\right)\right]$$

- $tr\left(\nabla_{\mathbf{x}} s_{\boldsymbol{\theta}}(\mathbf{x})\right)$ – след матрицы Якоби функции $s_{\boldsymbol{\theta}}(\mathbf{x})$

Доказательство $(1D)$:

$$\mathbb{E}_{p_{data}(x)}\left[\frac{1}{2}||s_{\boldsymbol{\theta}}(x) - s_{data}(x)||^2\right] = \mathbb{E}_{p_{data}(x)}\left[\frac{1}{2}s_{\boldsymbol{\theta}}(x)^2 + \frac{1}{2}s_{data}(x)^2 - s_{\boldsymbol{\theta}}(x) \cdot s_{data}(x)\right]$$

$\frac{1}{2}s_{data}(x)^2 = const$ относительно параметров $\boldsymbol{\theta}$

Score Matching

Преобразуем перекрёстное слагаемое:

$$\mathbb{E}_{p_{data}(\mathbf{x})}[s_{\boldsymbol{\theta}}(x) \cdot s_{data}(x)] = \int p_{data}(x) \cdot s_{\boldsymbol{\theta}}(x) \cdot \nabla_x \log p_{data}(x)\, dx =$$

$$= \int p_{data}(x) \cdot s_{\boldsymbol{\theta}}(x) \cdot \frac{1}{p_{data}(x)} \cdot \nabla_x\, p_{data}(x) dx = \int s_{\boldsymbol{\theta}}(x) \cdot \nabla_x\, p_{data}(x) dx =$$

$$= s_{\boldsymbol{\theta}}(x) \cdot p_{data}\,(x)\Big|_{-\infty}^{\infty} - \int \nabla_x\, s_{\boldsymbol{\theta}}(x) \cdot p_{data}\,(x) dx = -\int \nabla_x\, s_{\boldsymbol{\theta}}(x) \cdot p_{data}\,(x) dx =$$

$$= -\mathbb{E}_{p_{data}(\mathbf{x})}\,[\nabla_x\, s_{\boldsymbol{\theta}}(x)]$$

- $s_{\boldsymbol{\theta}}(x) \cdot p_{data}\,(x)|_{-\infty}^{\infty} \to 0$

Score Matching

Мы показали:

$$D_F\left(p_{data}(x)||p_{\boldsymbol{\theta}}(x)\right) = \mathbb{E}_{p_{data}(x)}\left[\frac{1}{2}s_{\boldsymbol{\theta}}(x)^2 + \nabla_x\, s_{\boldsymbol{\theta}}(x)\right] + C$$

В многомерном случае:

- $s_{\boldsymbol{\theta}}(x)^2 = (\nabla_{\mathbf{x}} \log p_{\boldsymbol{\theta}}(\mathbf{x}))^2 \rightarrow \left|\left|\nabla_{\mathbf{x}} \log p_{\boldsymbol{\theta}}(\mathbf{x})\right|\right|^2$
- $\nabla_x\, s_{\boldsymbol{\theta}}(x) = \nabla_{\mathbf{x}}^2 \log p_{\boldsymbol{\theta}}(\mathbf{x}) \rightarrow tr(\nabla_{\mathbf{x}}^2 \log p_{\boldsymbol{\theta}}(\mathbf{x}))$

В итоге

$$D_F\left(p_{data}(\mathbf{x})||p_{\boldsymbol{\theta}}(\mathbf{x})\right) = \mathbb{E}_{p_{data}(\mathbf{x})}\left[\frac{1}{2}||s_{\boldsymbol{\theta}}(\mathbf{x})||^2 + tr\left(\nabla_{\mathbf{x}} s_{\boldsymbol{\theta}}(\mathbf{x})\right)\right]$$

Подход, использующий такую функцию потерь был назван ***Implicit Score Matching***, поскольку избегает вычисления истинной *score*-функции $s_{data}(\mathbf{x})$

Denoising Score Matching

Проблемы *Score Matching*

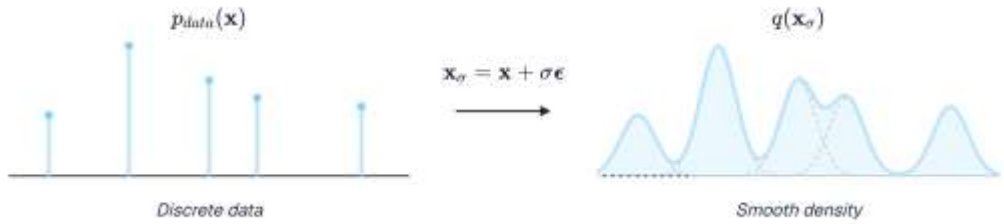
- Классический $\mathbf{score} - \boldsymbol{matching}$ требует, чтобы $p_{data}(\mathbf{x})$ была положительной и непрерывно дифференцируемой

- Реальные данные часто могут быть дискретны (изображения $0 - 255$)
- Для таких данных $\log p_{data}(\mathbf{x})$ является разрывной функцией

Идея:

Добавим небольшой шум к нашим данным*:*

$$\mathbf{x}_\sigma = \mathbf{x} + \sigma \cdot \boldsymbol{\epsilon}, \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I})$$



Процесс добавления шума описывается условной вероятностью:

$$q(\mathbf{x}_{\boldsymbol{\sigma}}|\mathbf{x}) = \mathcal{N}(\mathbf{x}_{\boldsymbol{\sigma}}|\mathbf{x}, \sigma^2 \cdot \boldsymbol{I})$$

Denoising Score Matching

Мы получили новое гладкое распределение, к которому можно применять **score – *matching***:

$$q(\mathbf{x}_{\boldsymbol{\sigma}}) = \int q(\mathbf{x}_{\boldsymbol{\sigma}}|\mathbf{x}) \cdot p_{data}(\mathbf{x})\, d\mathbf{x}$$

Будем минимизировать дивергенцию Фишера между *score*-функцией модели $s_{\boldsymbol{\theta}}(\mathbf{x})$ и *score*-функцией зашумленных данных $q(\mathbf{x}_{\boldsymbol{\sigma}})$:

$$\frac{1}{2}\mathbb{E}_{q(\mathbf{x}_{\boldsymbol{\sigma}})}\left[\left|\left|s_{\boldsymbol{\theta}}(\mathbf{x}_{\boldsymbol{\sigma}}) - \nabla_{\mathbf{x}_{\boldsymbol{\sigma}}} \log q(\mathbf{x}_{\boldsymbol{\sigma}})\right|\right|_2^2\right] \rightarrow \min_{\boldsymbol{\theta}}$$

Проблема:

Мы по-прежнему не знаем $\nabla_{\mathbf{x}_{\boldsymbol{\sigma}}} \log q(\mathbf{x}_{\boldsymbol{\sigma}})$, так как $q(\mathbf{x}_{\boldsymbol{\sigma}})$ зависит от $p_{data}(\mathbf{x})$:

Теорема *Denoising Score Matching*

Vincent (2010) показал, что минимизация дивергенции Фишера эквивалентна минимизации новой функции потерь:

$$\mathbb{E}_{q(\mathbf{x}_{\boldsymbol{\sigma}})}\left[\left|\left|s_{\boldsymbol{\theta}}(\mathbf{x}_{\boldsymbol{\sigma}}) - \nabla_{\mathbf{x}_{\boldsymbol{\sigma}}} \log q(\mathbf{x}_{\boldsymbol{\sigma}})\right|\right|_2^2\right] = \mathbb{E}_{p_{data}(\mathbf{x})}\mathbb{E}_{q(\mathbf{x}_{\sigma}|\mathbf{x})}\left[\left|\left|s_{\boldsymbol{\theta}}(\mathbf{x}_{\boldsymbol{\sigma}}) - \nabla_{\mathbf{x}_{\boldsymbol{\sigma}}} \log q(\mathbf{x}_{\sigma}|\mathbf{x})\right|\right|^2\right] + const$$

Факт:

Для любой функции $h(\mathbf{x}_{\boldsymbol{\sigma}})$:

$$\mathbb{E}_{q(\mathbf{x}_{\boldsymbol{\sigma}})}[h(\mathbf{x}_{\boldsymbol{\sigma}})] = \int q(\mathbf{x}_{\sigma}) h(\mathbf{x}_{\boldsymbol{\sigma}}) d\mathbf{x}_{\boldsymbol{\sigma}} = \int \left(\int q(\mathbf{x}_{\sigma}|\mathbf{x}) p_{data}(\mathbf{x}) d\mathbf{x} \right) h(\mathbf{x}_{\boldsymbol{\sigma}}) d\mathbf{x}_{\boldsymbol{\sigma}} = \mathbb{E}_{p_{data}(\mathbf{x})}\mathbb{E}_{q(\mathbf{x}_{\sigma}|\mathbf{x})}[h(\mathbf{x}_{\boldsymbol{\sigma}})]$$

Теорема *Denoising Score Matching*

Докажем:

$$\mathbb{E}_{q(\mathbf{x}_\sigma)}\left[\left|\left|s_{\boldsymbol{\theta}}(\mathbf{x}_{\boldsymbol{\sigma}}) - \nabla_{\mathbf{x}_{\boldsymbol{\sigma}}} \log q(\mathbf{x}_{\boldsymbol{\sigma}})\right|\right|_2^2\right] = \mathbb{E}_{p_{data}(\mathbf{x})}\mathbb{E}_{q(\mathbf{x}_\sigma|\mathbf{x})}\left[\left|\left|s_{\boldsymbol{\theta}}(\mathbf{x}_{\boldsymbol{\sigma}}) - \nabla_{\mathbf{x}_{\boldsymbol{\sigma}}} \log q(\mathbf{x}_{\boldsymbol{\sigma}}|\mathbf{x})\right|\right|^2\right] + const$$

Доказательство:

$$\mathbb{E}_{q(\mathbf{x}_\sigma)}\left[\left|\left|s_{\boldsymbol{\theta}}(\mathbf{x}_{\boldsymbol{\sigma}}) - \nabla_{\mathbf{x}_{\boldsymbol{\sigma}}} \log q(\mathbf{x}_{\boldsymbol{\sigma}})\right|\right|_2^2\right] = \mathbb{E}_{q(\mathbf{x}_\sigma)}\left[||s_{\boldsymbol{\theta}}(\mathbf{x}_{\boldsymbol{\sigma}})||^2 - 2s_\theta(\mathbf{x}_\sigma)^T \cdot \nabla_{\mathbf{x}_\sigma} \log q(\mathbf{x}_\sigma) + ||\nabla_{\mathbf{x}_{\boldsymbol{\sigma}}} \log q(\mathbf{x}_{\boldsymbol{\sigma}})||^2\right]$$

$$\mathbb{E}_{q(\mathbf{x}_\sigma)}\left[s_\theta(\mathbf{x}_\sigma)^T \cdot \nabla_{\mathbf{x}_\sigma} \log q(\mathbf{x}_\sigma)\right] = \int q(\mathbf{x}_{\boldsymbol{\sigma}})\left[s_{\boldsymbol{\theta}}(\mathbf{x}_\sigma)^T \frac{\nabla_{\mathbf{x}_{\boldsymbol{\sigma}}} q(\mathbf{x}_{\boldsymbol{\sigma}})}{q(\mathbf{x}_{\boldsymbol{\sigma}})}\right] d\mathbf{x}_{\boldsymbol{\sigma}}$$

$$= \int s_{\boldsymbol{\theta}}(\mathbf{x}_\sigma)^T \nabla_{\mathbf{x}_{\boldsymbol{\sigma}}}\left[\int q(\mathbf{x}_\sigma|\mathbf{x}) p_{data}(\mathbf{x}) d\mathbf{x}\right] d\mathbf{x}_{\boldsymbol{\sigma}} = \int\int p_{data}(\mathbf{x})[s_{\boldsymbol{\theta}}(\mathbf{x}_\sigma)^T \nabla_{\mathbf{x}_\sigma} q(\mathbf{x}_\sigma|\mathbf{x})]\, d\mathbf{x}_{\boldsymbol{\sigma}} d\mathbf{x}$$

$$= \int\int p_{data}(\mathbf{x}) \cdot q(\mathbf{x}_\sigma|\mathbf{x})[s_{\boldsymbol{\theta}}(\mathbf{x}_\sigma)^T \nabla_{\mathbf{x}_\sigma} \log q(\mathbf{x}_\sigma|\mathbf{x})]\, d\mathbf{x}_{\boldsymbol{\sigma}} d\mathbf{x} = \mathbb{E}_{p_{data}(\mathbf{x})}\mathbb{E}_{q(\mathbf{x}_\sigma|\mathbf{x})}[s_\theta(\mathbf{x}_\sigma)^T \nabla_{\mathbf{x}_\sigma} \log q(\mathbf{x}_\sigma|\mathbf{x})]$$

Теорема *Denoising Score Matching*

Докажем:

$$\mathbb{E}_{q(\mathbf{x}_{\boldsymbol{\sigma}})}\left[\left|\left|s_{\boldsymbol{\theta}}(\mathbf{x}_{\boldsymbol{\sigma}}) - \nabla_{\mathbf{x}_{\boldsymbol{\sigma}}} \log q(\mathbf{x}_{\boldsymbol{\sigma}})\right|\right|_2^2\right] = \mathbb{E}_{p_{data}(\mathbf{x})}\mathbb{E}_{q(\mathbf{x}_{\sigma}|\mathbf{x})}\left[\left|\left|s_{\boldsymbol{\theta}}(\mathbf{x}_{\boldsymbol{\sigma}}) - \nabla_{\mathbf{x}_{\boldsymbol{\sigma}}} \log q(\mathbf{x}_{\sigma}|\mathbf{x})\right|\right|^2\right] + const$$

Доказательство:

$$\mathbb{E}_{q(\mathbf{x}_{\boldsymbol{\sigma}})}\left[\left|\left|s_{\boldsymbol{\theta}}(\mathbf{x}_{\boldsymbol{\sigma}}) - \nabla_{\mathbf{x}_{\boldsymbol{\sigma}}} \log q(\mathbf{x}_{\boldsymbol{\sigma}})\right|\right|_2^2\right] = \mathbb{E}_{p_{data}(\mathbf{x})}\mathbb{E}_{q(\mathbf{x}_{\sigma}|\mathbf{x})}\left[||s_{\boldsymbol{\theta}}(\mathbf{x}_{\boldsymbol{\sigma}})||^2 - 2s_{\boldsymbol{\theta}}(\mathbf{x}_{\sigma})^T \cdot \nabla_{\mathbf{x}_{\sigma}} \log q(\mathbf{x}_{\sigma}|\mathbf{x})\right] + const(\boldsymbol{\theta})$$

$$= \mathbb{E}_{p_{data}(\mathbf{x})}\mathbb{E}_{q(\mathbf{x}_{\sigma}|\mathbf{x})}\left[\left|\left|s_{\boldsymbol{\theta}}(\mathbf{x}_{\boldsymbol{\sigma}}) - \nabla_{\mathbf{x}_{\sigma}} \log q(\mathbf{x}_{\sigma}|\mathbf{x})\right|\right|_2^2\right] + const(\boldsymbol{\theta})$$

Denoising Score Matching

Мы сами задаем $q(\mathbf{x}_\sigma|\mathbf{x})$:

$$q(\mathbf{x}_\sigma|\mathbf{x}) = \mathcal{N}(\mathbf{x}_\sigma|\mathbf{x}, \sigma^2\boldsymbol{I})$$

В этом случае *score*-функция вычисляется аналитически:

$$\nabla_{\mathbf{x}_\sigma} \log q(\mathbf{x}_\sigma|\mathbf{x}) = \nabla_{\mathbf{x}_\sigma}\left(-\frac{\left||\mathbf{x}_\sigma - \mathbf{x}|\right|^2}{2\sigma^2}\right) = -\frac{\mathbf{x}_\sigma - \mathbf{x}}{\sigma^2} = -\frac{\boldsymbol{\epsilon}}{\sigma}$$

Подставим в нашу функцию потерь*:*

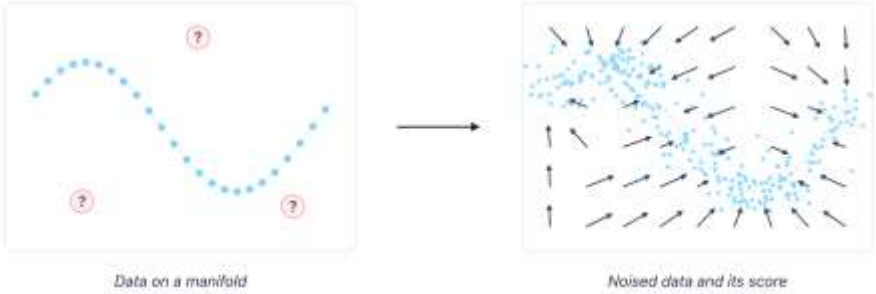
$$\frac{1}{2}\mathbb{E}_{p_{data}(\mathbf{x})}\mathbb{E}_{q(\mathbf{x}_\sigma|\mathbf{x})}\left[\left|\left|s_{\boldsymbol{\theta}}(\mathbf{x}_{\boldsymbol{\sigma}}) - \nabla_{\mathbf{x}_{\boldsymbol{\sigma}}} \log q(\mathbf{x}_\sigma|\mathbf{x})\right|\right|^2\right] = \frac{1}{2}\mathbb{E}_{p_{data}(\mathbf{x})}\mathbb{E}_{\mathcal{N}(\mathbf{0},\boldsymbol{I})}\left[\left|\left|s_{\boldsymbol{\theta}}(\mathbf{x} + \sigma\boldsymbol{\epsilon}) + \frac{\boldsymbol{\epsilon}}{\sigma}\right|\right|^2\right] \to \min_{\boldsymbol{\theta}}$$

- Нейросеть $s_{\boldsymbol{\theta}}(\mathbf{x}_{\boldsymbol{\sigma}})$ учится напрямую предсказывать шум $-\frac{\boldsymbol{\epsilon}}{\sigma}$, который был добавлен к $\mathbf{x}$

Обучение *Denoising Score Matching*

Обучение:

- Взять $\mathbf{x} \sim p_{data}$ и $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I})$
- Сделать $\mathbf{x}_\sigma = \mathbf{x} + \sigma \cdot \boldsymbol{\epsilon}$
- Посчитать $\frac{1}{2}\left|\left|s_{\boldsymbol{\theta}}(\mathbf{x}_\sigma) + \frac{\boldsymbol{\epsilon}}{\sigma}\right|\right|^2$ и сделать шаг градиента



Инференс:

- Запускаем динамику Ланжевена с обученным $s_{\boldsymbol{\theta}}(\mathbf{x}_\sigma)$:

$$\mathbf{x}_{t+1} = \mathbf{x}_t + \frac{\eta}{2} s_{\boldsymbol{\theta}}(\mathbf{x}_t) + \sqrt{\eta}\boldsymbol{\epsilon}_t$$

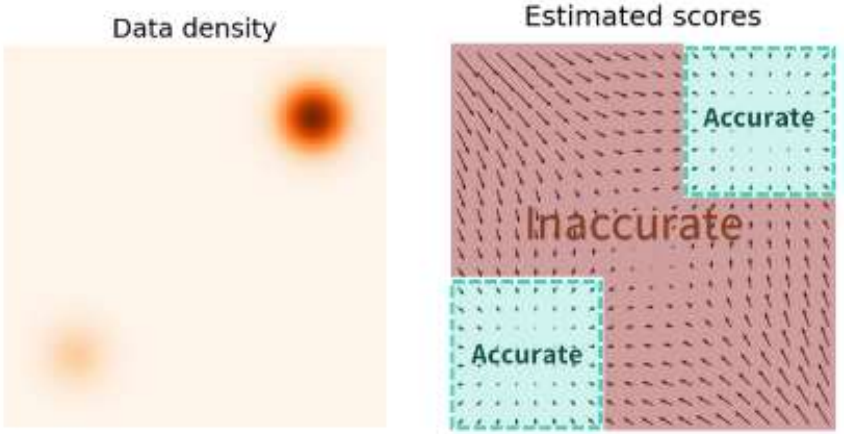
Модель выдает $-\frac{\boldsymbol{\epsilon}}{\sigma}$ то есть направление от зашумленной точки к чистому объекту:

$$\mathbf{x} \approx \mathbf{x}_\sigma + \sigma^2 s_{\boldsymbol{\theta}}(\mathbf{x}_\sigma) = \mathbf{x}_\sigma - \sigma \cdot \boldsymbol{\epsilon}$$

Проблема *Denoising Score Matching*

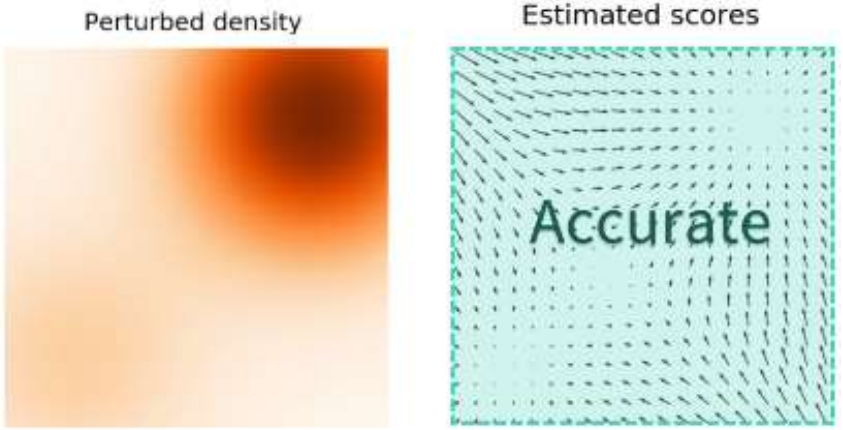
Если σ маленький:

- $q(\mathbf{x}_{\boldsymbol{\sigma}}) \approx p_{data}(\mathbf{x})$
- Функция потерь *DSM* содержит члены $\frac{1}{\sigma}$ и $\frac{1}{\sigma^2}$, что приводит к высокой дисперсии градиентов
- Обучение нестабильно, динамика Ланжевена застревает в модах



Если σ большой:

- Функция потерь *DSM* с низкой дисперсией градиентов
- $q(\mathbf{x}_{\boldsymbol{\sigma}}) \neq p_{data}(\mathbf{x})$ – сильно размытое распределение
- Модель хорошо работает в областях с низкой плотностью, но изучает искаженное распределение



Noise Conditioned Score Network

Noise Conditioned Score Network

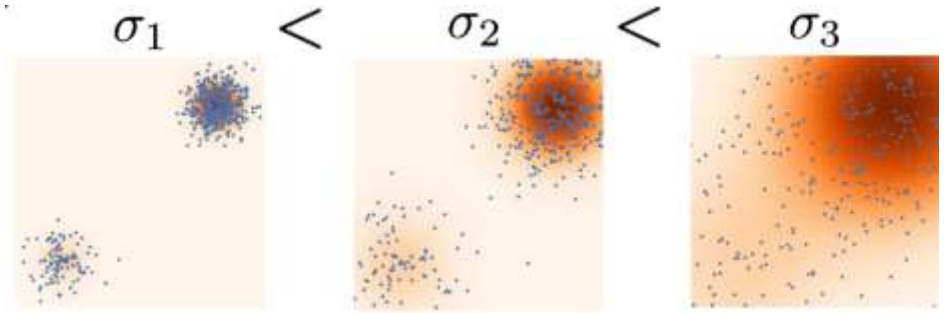
Идея:

Будем одновременно использовать несколько уровней шума

- Определим последовательность уровней шума $\sigma_1 < \sigma_2 < \cdots < \sigma_T$:

- $\sigma_1 -$ небольшой шум, $q(\mathbf{x}_1) \approx p_{data}(\mathbf{x})$
- $\sigma_T -$ большой шум, $q(\mathbf{x}_T) \approx \mathcal{N}(0, \sigma_T^2 \boldsymbol{I})$

- Каждому σ_t будет соответствовать свое распределение $q(\mathbf{x}_t)$



Обучение $NCSN$

Будем обучать $s_{\boldsymbol{\theta},\sigma_t}(\mathbf{x}_t)$ на каждом уровне шума, используя взвешенную функцию потерь DSM:

$$\mathcal{L}_{\boldsymbol{\theta}} = \sum_{t=1}^{T} \lambda(\sigma_t) \cdot \mathbb{E}_{p_{data}(\mathbf{x})} \mathbb{E}_{q(\mathbf{x}_t|\mathbf{x})} \left[\left|\left| s_{\boldsymbol{\theta},\sigma_t}(\mathbf{x}_t) - \nabla_{\mathbf{x}_t} \log q(\mathbf{x}_{\boldsymbol{t}}|\mathbf{x}) \right|\right|^2 \right],$$

где $\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_{\boldsymbol{t}}|\mathbf{x}) = -\frac{\boldsymbol{\epsilon}}{\sigma_t}$

Обычно веса $\lambda(\sigma_t)$ берут в виде σ_t^2, чтобы сбалансировать члены с $\frac{1}{\sigma_t^2}$

$$\mathcal{L}_{\boldsymbol{\theta}} = \sum_{t=1}^{T} \sigma_t^2 \cdot \mathbb{E}_{p_{data}(\mathbf{x})} \mathbb{E}_{q(\mathbf{x}_t|\mathbf{x})} \left[\left|\left| s_{\boldsymbol{\theta},\sigma_t}(\mathbf{x}_t) - \nabla_{\mathbf{x}_t} \log q(\mathbf{x}_{\boldsymbol{t}}|\mathbf{x}) \right|\right|^2 \right]$$

Обучение $NCSN$

Алгоритм обучения:

- Берем сэмпл $\mathbf{x}_0 \sim p_{data}(\mathbf{x})$
- Случайно выбираем уровень шума $t \sim U(1, T)$
- Сэмплируем шум $\epsilon \sim \mathcal{N}(0, \boldsymbol{I})$
- Создаем зашумленный сэмпл $\mathbf{x}_t = \mathbf{x}_0 + \sigma_t \cdot \boldsymbol{\epsilon}$
- Вычисляем лосс $\mathcal{L}_{\boldsymbol{\theta},\, t} = \sigma_t^2 \left\| s_{\boldsymbol{\theta},\sigma_t}(\mathbf{x}_t) + \frac{\boldsymbol{\epsilon}}{\sigma_t} \right\|^2$

Annealed Langevin Dynamics

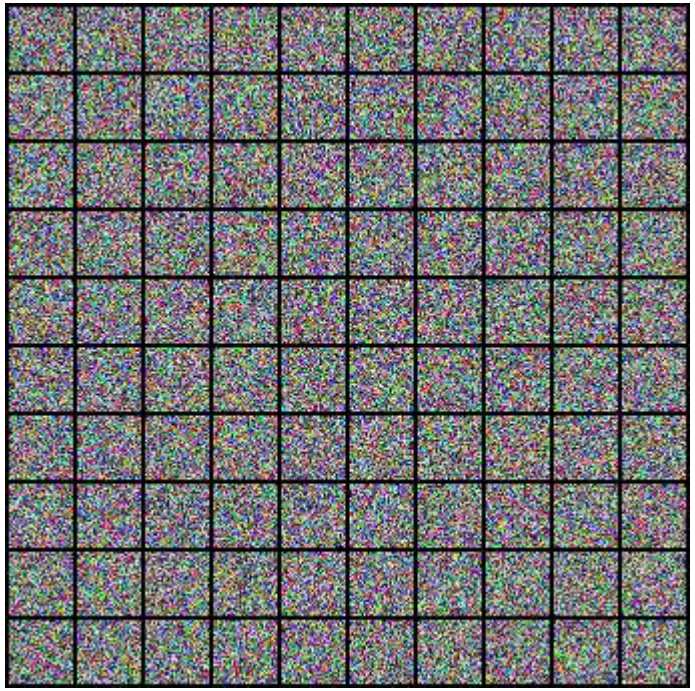
Для сэмплирования из модели используют ***динамику Ланжевена с отжигом*** (***Annealed Langevin Dynamics***):

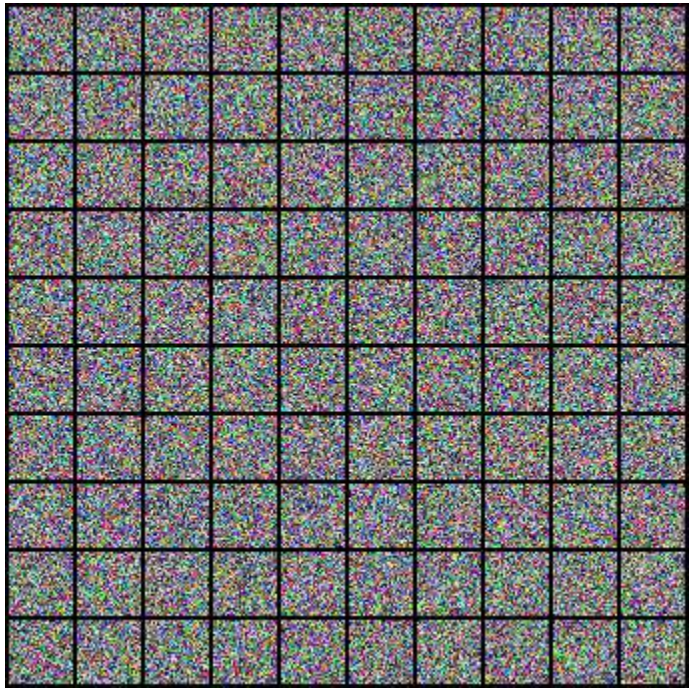
- Начинаем с шума $\mathbf{x}_T \sim \mathcal{N}(0, \sigma_T^2 \boldsymbol{I})$
- Для текущего шума σ_t применяем L шагов динамики Ланжевена*:*

$$\mathbf{x}_l = \mathbf{x}_{l-1} + \frac{\eta}{2} s_{\boldsymbol{\theta},\sigma_t}(\mathbf{x}_{l-1}) + \sqrt{\eta_t}\boldsymbol{\epsilon}_l$$

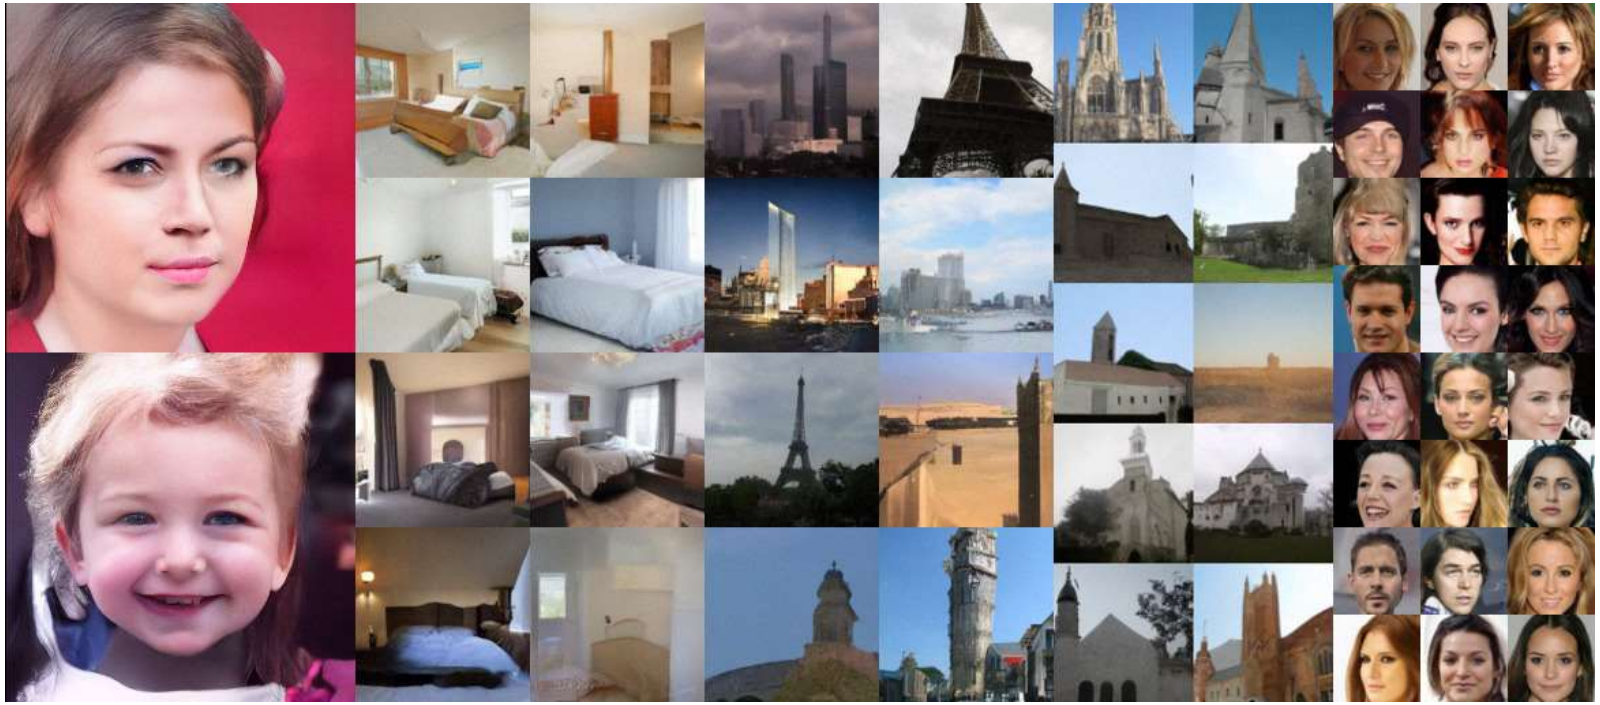
- После L шагов выход $\mathbf{x}_L$ становится инициализацией $\mathbf{x}_{t-1}$ для следующего уровня шума σ_{t-1}

Annealed Langevin Dynamics for NCSN





NCSN Samples



Спасибо за внимание!